In [60]:

```
%reload_ext watermark
%watermark
```

```
2019-05-30T21:34:58+02:00

CPython 3.6.5
IPython 6.4.0

compiler   : GCC 7.2.0
system     : Linux
release    : 5.1.5-arch1-2-ARCH
machine    : x86_64
processor  :
CPU cores  : 4
interpreter: 64bit
```

Procesado de variables

In [1]:

```
%matplotlib inline
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
```

In [2]:

```
datos = pd.read_csv("../../RESOURCES/datos_procesamiento.csv")
datos.head()
```

Out[2]:

	col_inexistente1	col2	col3	col_outliers	col_outliers2	col_categorica	col_ordinal	col_texto
0	59.0	52.0	2.232832	-50	0.771666	ratón	muy bien	Tenía en su casa una ama que pasaba de los cua...
1	31.0	74.0	0.906147	-5	1.068558	elefante	regular	El resto della concluían sayo de velarte, calz...
2	81.0	28.0	0.626750	-32	0.846396	ratón	muy mal	El resto della concluían sayo de velarte, calz...
3	34.0	16.0	0.816738	-84	0.637381	gato	mal	Una olla de algo más vaca que carnero, salpicó...
4	32.0	28.0	0.571131	65	4.540614	gato	bien	Tenía en su casa una ama que pasaba de los cua...

In [3]:

```
datos.dtypes
```

Out[3]:

```
col_inexistente1    float64
col2                float64
col3                float64
col_outliers          int64
col_outliers2       float64
col_categorica       object
col_ordinal          object
col_texto            object
dtype: object
```

In [4]:

```
datos.shape
```

Out[4]:

```
(1000, 8)
```

Variables numéricas

Imputacion de datos

In [5]:

```
from sklearn import preprocessing
```

In [6]:

```
#Seleccionamos todas aquellas columnas que sean int o float, quitando asi las de string
var_numericas_df = datos.select_dtypes([int,float])
var_numericas_df.columns
```

Out[6]:

```
Index(['col_inexistente1', 'col2', 'col3', 'col_outliers', 'col_outliers2'], dtype='object')
```

In [7]:

```
#vamos a ver cuantos casos son NaN
var_numericas_df[var_numericas_df.isnull().any(axis=1)].shape
```

Out[7]:

```
(96, 5)
```

In [8]:

```
var_numericas_df[var_numericas_df.isnull().any(axis=1)].head()
```

Out[8]:

	col_inexistente1	col2	col3	col_outliers	col_outliers2
9	NaN	53.0	2.270999	62	1.067230
10	NaN	99.0	1.394209	98	4.145716
16	NaN	50.0	0.437365	59	20.549474
17	NaN	73.0	0.324893	98	0.761684
23	NaN	85.0	3.664671	-48	3.154153

In [9]:

```
#mediante el imputador preprocesamos el dataset mediante una estrategia, en este caso la media.
imputador = preprocessing.Imputer(strategy="mean")
```

```
/opt/anaconda3/lib/python3.6/site-packages/sklearn/utils/deprecation.py:58: DeprecationWarning: Class Imputer is deprecated; Imputer was deprecated in version 0.20 and will be removed in 0.22. Import impute.SimpleImputer from sklearn instead.
  warnings.warn(msg, category=DeprecationWarning)
```

In [10]:

```
var_numericas_imputadas = imputador.fit_transform(var_numericas_df)
```

In [11]:

```
var_numericas_imputadas
```

Out[11]:

```
array([[ 59.        ,  52.        ,   2.23283208, -50.        ,
          0.77166646],
       [ 31.        ,  74.        ,   0.90614714,  -5.        ,
          1.06855838],
       [ 81.        ,  28.        ,   0.62675042, -32.        ,
          0.84639576],
       ...,
       [ 19.        ,  53.        ,   0.73723413,  73.        ,
          1.34525201],
       [ 88.        ,  94.        ,   0.76008706,  68.        ,
```

```
        1.3692463 ],
       [ 94.        ,  56.        ,   1.2299403 ,  61.        ,
        0.94395714]])
```

In [12]:

```
#convertimos el array de numpy del imputador a un dataframe
var_numericas_imputadas_df = pd.DataFrame(
    var_numericas_imputadas,index=var_numericas_df.index,columns=var_numericas_df.columns
)
var_numericas_imputadas_df.head(10)
```

Out[12]:

	col_inexistente1	col2	col3	col_outliers	col_outliers2
0	59.000000	52.0	2.232832	-50.0	0.771666
1	31.000000	74.0	0.906147	-5.0	1.068558
2	81.000000	28.0	0.626750	-32.0	0.846396
3	34.000000	16.0	0.816738	-84.0	0.637381
4	32.000000	28.0	0.571131	65.0	4.540614
5	81.000000	4.0	1.618844	51.0	0.812940
6	57.000000	31.0	0.167880	78.0	1.235137
7	34.000000	20.0	20.229813	93.0	1.283176
8	37.000000	96.0	2.407978	54.0	1.298613
9	48.382743	53.0	2.270999	62.0	1.067230

In [13]:

```
#Comprobamos que ahora ya no hay variables nulas
var_numericas_imputadas_df[var_numericas_imputadas_df.isnull().any(axis=1)].shape
```

Out[13]:

```
(0, 5)
```

Estandarizacion

El proceso de estandarizacion es un proceso requerido en el que el objetivo es obtener una variable con media 0 y desviacion estandar 1

In [14]:

```
var_numericas_df.columns
```

Out[14]:

```
Index(['col_inexistente1', 'col2', 'col3', 'col_outliers', 'col_outliers2'], dtype='object')
```

In [15]:

```
#ibtenemos la media de cada una de las columnasabs
var_numericas_df.mean()
```

Out[15]:

```
col_inexistente1     48.382743
col2                 49.660000
col3                  1.466095
col_outliers          4.253000
col_outliers2       131.193340
dtype: float64
```

In [16]:

```
#obtenemos la desviacion estandar de cada una de las columnas
var_numericas_df.std()
```

Out[16]:

```
col_inexistente1      27.987174
col2                  28.272668
```

```
col3                  1.732358
col_outliers         78.145901
col_outliers2      3401.164776
dtype: float64
```

Ahora procedemos a estandarizar el dataframe, para ello utilizaremos una herramienta de sklearn: **StandardScaler**

In [17]:

```
escalador = preprocessing.StandardScaler()
var_numericas_imputadas_escalado_standard = escalador.fit_transform(var_numericas_imputadas)
```

In [18]:

```
escalador.mean_
```

Out[18]:

```
array([ 48.38274336,  49.66      ,   1.46609489,   4.253     ,
       131.19333968])
```

In [19]:

```
#Observamos la media despues de la estandarizacion, en la que sus campos son muy proximos a 0
var_numericas_imputadas_escalado_standard.mean(axis=0)
```

Out[19]:

```
array([-5.86197757e-17,  1.26121336e-16, -3.81916720e-17,  3.55271368e-18,
       -3.55271368e-18])
```

In [20]:

```
#Observamos la desviacion estandard y comprobamos que es 1
var_numericas_imputadas_escalado_standard.std(axis=0)
```

Out[20]:

```
array([1., 1., 1., 1., 1.])
```

In [21]:

```
#Observamos la primera observacion
var_numericas_imputadas_escalado_standard[0]
```

Out[21]:

```
array([ 0.39921733,  0.08280686,  0.44281884, -0.69460006, -0.03836537])
```

Para aquellos datasets con valores muy extremos, esta herramienta no sería la mas apropiada y sería más optimo usar estimadores mas robustos (menos sensibles a los Outliers). Para ello podemos emplear **RobustScaler** que funciona substrayendo la mediana y escalando mediante el rango intercuartil (IQR). (Este escalador robusto funciona igual que el anterior, salvo por la diferencia de que en vez de la media utiliza la mediana y en ver de la desviacion estandard utiliza el rango intercuartil)

In [22]:

```
escalador_robusto = preprocessing.RobustScaler()
var_numericas_imputadas_escalado_robusto = escalador_robusto.fit_transform(var_numericas_imputadas
)
```

In [23]:

```
var_numericas_imputadas_escalado_robusto.mean(axis=0)
```

Out[23]:

```
array([-3.81916720e-17, -2.85106383e-02,  4.01958704e-01,  3.04018692e-02,
        7.03130782e+01])
```

In [24]:

```
var_numericas_imputadas_escalado_robusto.std(axis=0)
```

Out[24]:

```
array([6.33218559e-01, 6.01245275e-01, 1.38651621e+00, 7.29970260e-01,
       1.83690817e+03])
```

Escalado a un rango especifico.

Hay casos en los que en vez de estandarizar el modelo nos interesa mas ajustar los datos a un rango especifico (generalmente -1,1 o 0,1). Para ello utilizamos la herramienta **MinMaxScaler** que hace escalado minmax. Tambien podemos utilizar el MaxAbsScaler que simplemente divide cada valor de una variable por su valor maximo (y por tanto convierte el valor maximo a 1)

In [25]:

```
#comprobamos el valor minimo antes del escalado
var_numericas_imputadas.min()
```

Out[25]:

```
-100.0
```

In [26]:

```
#comprobamos el valor maximo antes del escalado
var_numericas_imputadas.max()
```

Out[26]:

```
107357.85777352
```

In [27]:

```
#escalamos con la libreria preprocessing y la herramienta MinMaxScaler
escalador_minmax = preprocessing.MinMaxScaler()
var_numericas_imputadas_escalado_minmax = escalador_minmax.fit_transform(var_numericas_imputadas)
```

In [28]:

```
#comprobamos el minimo despues de escalarlo
var_numericas_imputadas_escalado_minmax.min()
```

Out[28]:

```
0.0
```

In [29]:

```
#comprobamos el maximo despues de escalarlo
var_numericas_imputadas_escalado_minmax.max()
```

Out[29]:

```
1.0
```

In [30]:

```
#creamos ahora un escalador con la herramienta MaxAbsScaler
escalador_maxabs = preprocessing.MaxAbsScaler()
var_numericas_imputadas_escalado_maxabs = escalador_maxabs.fit_transform(var_numericas_imputadas)
```

In [31]:

```
#comprobamos los maximos tras aplicar el escalador MaxAbs
var_numericas_imputadas_escalado_maxabs.max()
```

Out[31]:

```
1.0
```

In [32]:

```
#comprobamos los minimos tras aplicar el escalador MaxAbs y comprobamos que no se preocupa por el
minimo y solo
#divide por el maximo
var_numericas_imputadas_escalado_maxabs.min()
```

Out[32]:

```
-0.1122334455667789
```

Hay casos en los que es necesario tener observaciones con norma unitaria (norma L2 o euclidiana). Para estos casos se utilizará el método **normalizer**

In [33]:

```
normalizador = preprocessing.Normalizer()
```

```
var_numericas_imputadas_normal = normalizador.fit_transform(var_numericas_imputadas)
```

In [34]:

```
var_numericas_imputadas_normal[:1]
```

Out[34]:

```
array([[ 0.63288908,  0.55780055,  0.02395144, -0.53634668,  0.00827761]])
```

In [35]:

```
np.linalg.norm(var_numericas_imputadas[1,:])
```

Out[35]:

```
80.39877436664493
```

Otras transformaciones

Para aquellos casos en los que queremos aplicar una función arbitraria a una variable podemos usar **FunctionTransformer**. La variable *col3* no tiene una distribución normal, sino que tiene una asimetría muy marcada.

In [36]:

```
sns.kdeplot(datos.col3)
```

Out[36]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f1943176128>
```

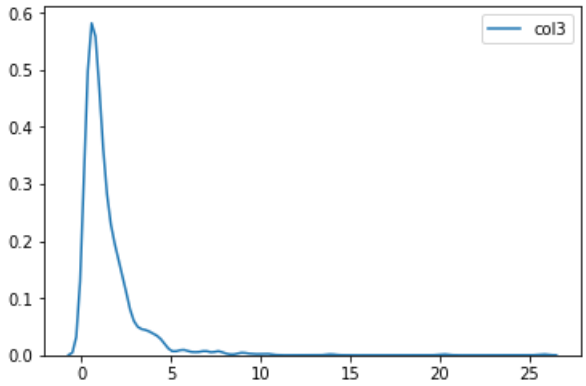

Una práctica muy frecuente es aplicar el logaritmo a dichas variables para convertirlas a variables con una distribución más normal.

In [37]:

```
from sklearn.preprocessing import FunctionTransformer
#la funcion np.log1p es para sumar siempre uno para evitar el logaritmo de 0 (que es infinito)
transformer = FunctionTransformer(np.log1p)
```

In [38]:

```
col3_transformada= transformer.transform(datos[["col3"]])
col3_transformada = col3_transformada.reshape(col3_transformada.shape[0],)
sns.kdeplot(col3_transformada)
```

```
/opt/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/_function_transformer.py:98:
FutureWarning: The default validate=True will be replaced by validate=False in 0.22.
  "validate=False in 0.22.", FutureWarning)
```

Out[38]:

```
<matplotlib.axes._subplots.AxesSubplot at 0x7f193ffd3e48>
```

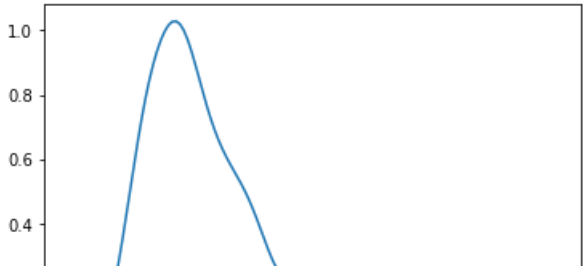

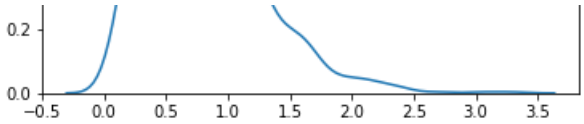

Vemos que tras aplicar el transformador de FunctionTransformer aplicando como parámetro la funcion logaritmo de numpy el resgistro de *col3* está mucho más normalizado

Variables Categóricas

Los modelos están diseñados para trabajar con variables numéricas. Esto implica que para poder entrenar los modelos con variables categóricas tenemos que convertirlas a números. Este proceso se le conoce como **codificación**(*encoding*). Básicamente el proceso consiste en utilizar los registros de texto en valores ordinarios.

In [39]:

```
datos = pd.read_csv("../../RESOURCES/datos_procesamiento.csv")
datos.head()
```

Out[39]:

	col_inexistente1	col2	col3	col_outliers	col_outliers2	col_categorica	col_ordinal	col_texto
0	59.0	52.0	2.232832	-50	0.771666	ratón	muy bien	Tenía en su casa una ama que pasaba de los cua...
1	31.0	74.0	0.906147	-5	1.068558	elefante	regular	El resto della concluían sayo de velarte, calz...
2	81.0	28.0	0.626750	-32	0.846396	ratón	muy mal	El resto della concluían sayo de velarte, calz...
3	34.0	16.0	0.816738	-84	0.637381	gato	mal	Una olla de algo más vaca que carnero, salpicó...
4	32.0	28.0	0.571131	65	4.540614	gato	bien	Tenía en su casa una ama que pasaba de los cua...

In [40]:

```
var_categoricas = datos[['col_categorica','col_ordinal']]
```

In [41]:

```
var_categoricas.head()
```

Out[41]:

	col_categorica	col_ordinal
0	ratón	muy bien
1	elefante	regular
2	ratón	muy mal
3	gato	mal
4	gato	bien

ahora debemos 'separar' estos valores por valores numéricos. A este proceso en Scikit Learn se conoce como **LabelEncoder**. En nuestro caso, como no queremos que los animales tengan un valor 'real' numerico (que no pueda darse una situación de que un ratón más un gato es igual a un elefante por ejemplo) lo que haremos será emplear una técnica conocida como **OneHotEncoder**.

LabelEncoder

Aplicamos un transformador LabelEncoder()

In [42]:

```
label_codificador_categorico=preprocessing.LabelEncoder()
label_codificador_categorico.fit_transform(datos.col_categorica)[:10]
```

Out[42]:

```
array([3, 0, 3, 1, 1, 2, 2, 2, 0, 0])
```

OneHotEncoder

Aplicamos un transformador OneHotEncoder()

In [43]:

```
ohcodificador = preprocessing.OneHotEncoder()
```

In [44]:

```
ohcodificador.fit(datos.col_categorica)
```

```
---------------------------------------------------------------------------
ValueError                                Traceback (most recent call last)
<ipython-input-44-f63cf08d548e> in <module>()
----> 1 ohcodificador.fit(datos.col_categorica)

/opt/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/_encoders.py in fit(self, X, y)
    427             return self
    428         else:
--> 429             self._fit(X, handle_unknown=self.handle_unknown)
    430             return self
    431

/opt/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/_encoders.py in _fit(self, X,
handle_unknown)
     59
     60     def _fit(self, X, handle_unknown='error'):
---> 61         X = self._check_X(X)
     62
     63         n_samples, n_features = X.shape

/opt/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/_encoders.py in _check_X(self, X)
     45
     46         """
---> 47         X_temp = check_array(X, dtype=None)
     48         if not hasattr(X, 'dtype') and np.issubdtype(X_temp.dtype, np.str_):
     49             X = check_array(X, dtype=np.object)

/opt/anaconda3/lib/python3.6/site-packages/sklearn/utils/validation.py in check_array(array,
accept_sparse, accept_large_sparse, dtype, order, copy, force_all_finite, ensure_2d, allow_nd,
ensure_min_samples, ensure_min_features, warn_on_dtype, estimator)
    550                     "Reshape your data either using array.reshape(-1, 1) if "
    551                     "your data has a single feature or array.reshape(1, -1) "
--> 552                     "if it contains a single sample.".format(array))
    553
    554         # in the future np.flexible dtypes will be handled like object dtypes

ValueError: Expected 2D array, got 1D array instead:
array=['ratón' 'elefante' 'ratón' 'gato' 'gato' 'perro' 'perro' 'perro'
 'elefante' 'elefante' 'perro' 'elefante' 'gato' 'ratón' 'gato' 'ratón'
 'elefante' 'ratón' 'ratón' 'elefante' 'ratón' 'ratón' 'ratón' 'gato'
 'gato' 'ratón' 'gato' 'elefante' 'gato' 'elefante' 'elefante' 'elefante'
 'elefante' 'ratón' 'elefante' 'gato' 'elefante' 'gato' 'gato' 'gato'
 'gato' 'ratón' 'elefante' 'gato' 'gato' 'perro' 'elefante' 'gato'
 'elefante' 'perro' 'ratón' 'perro' 'elefante' 'ratón' 'ratón' 'gato'
 'gato' 'elefante' 'ratón' 'perro' 'gato' 'gato' 'gato' 'gato' 'ratón'
 'elefante' 'elefante' 'perro' 'gato' 'ratón' 'perro' 'elefante' 'gato'
 'gato' 'ratón' 'ratón' 'elefante' 'perro' 'ratón' 'ratón' 'elefante'
 'gato' 'perro' 'ratón' 'gato' 'elefante' 'elefante' 'perro' 'perro'
 'perro' 'ratón' 'gato' 'ratón' 'gato' 'gato' 'elefante' 'gato' 'gato'
 'perro' 'perro' 'ratón' 'perro' 'gato' 'elefante' 'ratón' 'perro' 'gato'
 'gato' 'ratón' 'gato' 'perro' 'perro' 'perro' 'gato' 'perro' 'perro'
 'elefante' 'perro' 'ratón' 'gato' 'gato' 'gato' 'gato' 'ratón' 'ratón'
 'ratón' 'perro' 'elefante' 'elefante' 'perro' 'ratón' 'gato' 'elefante'
 'gato' 'ratón' 'ratón' 'elefante' 'gato' 'perro' 'ratón' 'gato'
 'elefante' 'elefante' 'elefante' 'elefante' 'perro' 'elefante' 'elefante'
 'gato' 'ratón' 'perro' 'perro' 'gato' 'perro' 'perro' 'elefante' 'gato'
 'perro' 'perro' 'perro' 'perro' 'gato' 'ratón' 'gato' 'gato' 'gato'
 'perro' 'ratón' 'ratón' 'elefante' 'ratón' 'ratón' 'elefante' 'elefante'
 'ratón' 'elefante' 'elefante' 'elefante' 'ratón' 'ratón' 'gato' 'perro'
```

'elefante' 'elefante' 'gato' 'gato' 'perro' 'elefante' 'elefante'
'elefante' 'ratón' 'perro' 'perro' 'gato' 'ratón' 'gato' 'perro' 'ratón'
'elefante' 'ratón' 'ratón' 'gato' 'ratón' 'gato' 'ratón' 'elefante'
'gato' 'gato' 'perro' 'elefante' 'perro' 'perro' 'gato' 'elefante'
'elefante' 'elefante' 'gato' 'perro' 'gato' 'perro' 'elefante' 'elefante'
'elefante' 'elefante' 'perro' 'gato' 'gato' 'elefante' 'ratón' 'perro'
'perro' 'ratón' 'ratón' 'perro' 'perro' 'elefante' 'elefante' 'perro'
'gato' 'perro' 'ratón' 'perro' 'ratón' 'gato' 'ratón' 'perro' 'elefante'
'gato' 'gato' 'ratón' 'ratón' 'perro' 'gato' 'ratón' 'ratón' 'perro'
'elefante' 'gato' 'ratón' 'perro' 'elefante' 'ratón' 'elefante' 'perro'
'ratón' 'perro' 'perro' 'perro' 'ratón' 'ratón' 'ratón' 'perro'
'elefante' 'perro' 'elefante' 'gato' 'elefante' 'elefante' 'elefante'
'elefante' 'ratón' 'elefante' 'ratón' 'elefante' 'perro' 'ratón' 'gato'
'elefante' 'perro' 'perro' 'ratón' 'perro' 'ratón' 'gato' 'gato' 'perro'
'gato' 'ratón' 'perro' 'elefante' 'gato' 'perro' 'gato' 'elefante'
'perro' 'ratón' 'gato' 'perro' 'elefante' 'elefante' 'gato' 'ratón'
'gato' 'elefante' 'perro' 'perro' 'ratón' 'gato' 'ratón' 'gato' 'perro'
'gato' 'perro' 'ratón' 'ratón' 'perro' 'ratón' 'gato' 'gato' 'ratón'
'ratón' 'gato' 'perro' 'elefante' 'elefante' 'gato' 'ratón' 'gato'
'ratón' 'gato' 'ratón' 'elefante' 'ratón' 'ratón' 'elefante' 'elefante'
'gato' 'elefante' 'ratón' 'elefante' 'perro' 'elefante' 'elefante'
'perro' 'gato' 'gato' 'elefante' 'perro' 'perro' 'perro' 'perro' 'gato'
'perro' 'ratón' 'ratón' 'gato' 'elefante' 'gato' 'gato' 'perro' 'ratón'
'perro' 'perro' 'elefante' 'ratón' 'ratón' 'gato' 'perro' 'perro'
'elefante' 'gato' 'perro' 'gato' 'gato' 'ratón' 'ratón' 'gato' 'perro'
'gato' 'ratón' 'perro' 'perro' 'ratón' 'gato' 'perro' 'perro' 'gato'
'gato' 'perro' 'elefante' 'ratón' 'ratón' 'perro' 'elefante' 'elefante'
'gato' 'ratón' 'elefante' 'perro' 'ratón' 'elefante' 'perro' 'perro'
'gato' 'elefante' 'elefante' 'elefante' 'ratón' 'perro' 'gato' 'gato'
'ratón' 'ratón' 'ratón' 'perro' 'elefante' 'gato' 'gato' 'gato' 'perro'
'elefante' 'gato' 'elefante' 'elefante' 'elefante' 'ratón' 'gato' 'perro'
'elefante' 'elefante' 'elefante' 'ratón' 'elefante' 'perro' 'ratón'
'ratón' 'ratón' 'elefante' 'ratón' 'ratón' 'gato' 'ratón' 'perro' 'perro'
'ratón' 'gato' 'elefante' 'perro' 'gato' 'gato' 'ratón' 'elefante'
'ratón' 'ratón' 'ratón' 'gato' 'ratón' 'perro' 'elefante' 'ratón' 'ratón'
'ratón' 'perro' 'ratón' 'ratón' 'perro' 'perro' 'gato' 'perro' 'ratón'
'perro' 'elefante' 'ratón' 'elefante' 'gato' 'perro' 'gato' 'elefante'
'ratón' 'perro' 'perro' 'gato' 'perro' 'gato' 'gato' 'perro' 'gato'
'elefante' 'elefante' 'ratón' 'ratón' 'gato' 'gato' 'gato' 'perro'
'elefante' 'gato' 'ratón' 'elefante' 'elefante' 'ratón' 'ratón' 'perro'
'gato' 'gato' 'elefante' 'elefante' 'ratón' 'elefante' 'gato' 'ratón'
'gato' 'gato' 'ratón' 'perro' 'ratón' 'elefante' 'ratón' 'elefante'
'gato' 'gato' 'gato' 'gato' 'perro' 'gato' 'gato' 'ratón' 'perro'
'elefante' 'gato' 'gato' 'ratón' 'perro' 'elefante' 'ratón' 'ratón'
'elefante' 'ratón' 'perro' 'gato' 'perro' 'perro' 'perro' 'perro' 'gato'
'ratón' 'gato' 'elefante' 'perro' 'gato' 'perro' 'ratón' 'ratón' 'perro'
'elefante' 'elefante' 'elefante' 'perro' 'perro' 'ratón' 'perro' 'perro'
'ratón' 'ratón' 'ratón' 'gato' 'perro' 'gato' 'gato' 'ratón' 'ratón'
'gato' 'perro' 'gato' 'ratón' 'perro' 'perro' 'perro' 'ratón' 'ratón'
'ratón' 'elefante' 'gato' 'gato' 'elefante' 'gato' 'gato' 'ratón' 'ratón'
'ratón' 'perro' 'perro' 'elefante' 'elefante' 'elefante' 'elefante'
'elefante' 'perro' 'ratón' 'ratón' 'ratón' 'gato' 'ratón' 'gato' 'gato'
'elefante' 'elefante' 'elefante' 'perro' 'ratón' 'perro' 'perro' 'perro'
'gato' 'ratón' 'elefante' 'perro' 'elefante' 'elefante' 'elefante'
'elefante' 'elefante' 'perro' 'elefante' 'perro' 'ratón' 'elefante'
'elefante' 'perro' 'gato' 'ratón' 'ratón' 'elefante' 'elefante' 'gato'
'ratón' 'ratón' 'ratón' 'elefante' 'ratón' 'ratón' 'perro' 'perro'
'perro' 'elefante' 'elefante' 'elefante' 'gato' 'ratón' 'elefante'
'ratón' 'gato' 'perro' 'gato' 'elefante' 'gato' 'ratón' 'gato' 'gato'
'elefante' 'gato' 'gato' 'elefante' 'perro' 'perro' 'gato' 'perro' 'gato'
'ratón' 'gato' 'ratón' 'perro' 'perro' 'ratón' 'elefante' 'perro' 'perro'
'gato' 'perro' 'gato' 'perro' 'elefante' 'ratón' 'elefante' 'perro'
'perro' 'gato' 'perro' 'perro' 'gato' 'ratón' 'gato' 'gato' 'elefante'
'gato' 'perro' 'gato' 'gato' 'perro' 'gato' 'ratón' 'ratón' 'perro'
'gato' 'gato' 'elefante' 'ratón' 'perro' 'elefante' 'elefante' 'ratón'
'ratón' 'perro' 'gato' 'perro' 'ratón' 'gato' 'gato' 'perro' 'perro'
'perro' 'gato' 'perro' 'elefante' 'elefante' 'perro' 'perro' 'elefante'
'ratón' 'gato' 'ratón' 'gato' 'elefante' 'elefante' 'perro' 'ratón'
'gato' 'elefante' 'perro' 'perro' 'gato' 'gato' 'ratón' 'perro' 'perro'
'ratón' 'perro' 'ratón' 'gato' 'perro' 'elefante' 'ratón' 'ratón' 'perro'
'gato' 'perro' 'perro' 'perro' 'elefante' 'perro' 'gato' 'ratón' 'ratón'
'perro' 'ratón' 'gato' 'gato' 'ratón' 'perro' 'ratón' 'ratón' 'perro'
'elefante' 'gato' 'ratón' 'elefante' 'elefante' 'perro' 'gato' 'perro'
'perro' 'gato' 'ratón' 'perro' 'ratón' 'gato' 'ratón' 'elefante'
'elefante' 'perro' 'elefante' 'perro' 'gato' 'ratón' 'gato' 'perro'
'elefante' 'elefante' 'ratón' 'elefante' 'ratón' 'elefante' 'elefante'
'ratón' 'perro' 'perro' 'perro' 'elefante' 'ratón' 'gato' 'gato' 'gato'

```
 'perro' 'elefante' 'elefante' 'elefante' 'gato' 'elefante' 'perro' 'gato'
 'elefante' 'elefante' 'ratón' 'gato' 'gato' 'ratón' 'perro' 'elefante'
 'perro' 'perro' 'perro' 'elefante' 'perro' 'perro' 'elefante' 'perro'
 'elefante' 'gato' 'elefante' 'gato' 'gato' 'perro' 'gato' 'ratón'
 'elefante' 'perro' 'perro' 'perro' 'elefante' 'perro' 'ratón' 'gato'
 'elefante' 'gato' 'ratón' 'gato' 'gato' 'ratón' 'elefante' 'gato'
 'elefante' 'elefante' 'gato' 'perro' 'gato' 'elefante' 'perro' 'ratón'
 'elefante' 'elefante' 'elefante' 'elefante' 'perro' 'ratón' 'perro'
 'ratón' 'gato' 'elefante' 'ratón' 'ratón' 'perro' 'elefante' 'ratón'
 'ratón' 'perro' 'gato' 'elefante' 'ratón' 'ratón' 'gato' 'gato'
 'elefante' 'perro' 'elefante' 'perro' 'gato' 'perro' 'perro' 'perro'
 'perro' 'ratón' 'ratón' 'gato' 'perro' 'gato' 'elefante' 'perro' 'ratón'
 'perro' 'ratón' 'perro' 'gato' 'elefante' 'ratón' 'gato' 'perro' 'ratón'
 'perro' 'elefante' 'gato' 'ratón' 'perro' 'elefante' 'ratón' 'ratón'
 'ratón' 'perro' 'gato' 'gato' 'gato' 'perro' 'ratón' 'perro' 'ratón'
 'elefante' 'perro' 'perro' 'ratón' 'elefante' 'ratón' 'elefante' 'ratón'
 'gato' 'gato' 'gato' 'perro' 'elefante' 'gato' 'perro' 'gato' 'ratón'
 'ratón' 'gato' 'elefante' 'gato' 'elefante' 'elefante' 'gato' 'ratón'
 'ratón' 'ratón' 'gato' 'elefante' 'perro' 'perro' 'elefante' 'ratón'
 'perro' 'elefante' 'ratón' 'gato' 'perro' 'ratón' 'gato' 'gato' 'ratón'
 'ratón' 'gato' 'perro' 'perro' 'perro' 'elefante' 'gato' 'ratón' 'ratón'
 'elefante' 'ratón' 'elefante' 'elefante' 'elefante'].
Reshape your data either using array.reshape(-1, 1) if your data has a single feature or
array.reshape(1, -1) if it contains a single sample.
```

Vemos que el transformador OneHotEncoder falla cuando recibe cadenas en vez de numeros. Por ello debemos convertir las variables categóricas a numéricas usando LabelEncoder.

In [45]:

```
categorias_codificadas = label_codificador_categorico.transform(datos.col_categorica)
```

In [46]:

```
categorias_codificadas
```

Out[46]:

```
array([3, 0, 3, 1, 1, 2, 2, 2, 0, 0, 2, 0, 1, 3, 1, 3, 0, 3, 3, 0, 3, 3,
       3, 1, 1, 3, 1, 0, 1, 0, 0, 0, 0, 3, 0, 1, 0, 1, 1, 1, 1, 3, 0, 1,
       1, 2, 0, 1, 0, 2, 3, 2, 0, 3, 3, 1, 1, 0, 3, 2, 1, 1, 1, 1, 3, 0,
       0, 2, 1, 3, 2, 0, 1, 1, 3, 3, 0, 2, 3, 3, 0, 1, 2, 3, 1, 0, 0, 2,
       2, 2, 3, 1, 3, 1, 1, 0, 1, 1, 2, 2, 3, 2, 1, 0, 3, 2, 1, 1, 3, 1,
       2, 2, 2, 1, 2, 2, 0, 2, 3, 1, 1, 1, 1, 3, 3, 3, 2, 0, 0, 2, 3, 1,
       0, 1, 3, 3, 0, 1, 2, 3, 1, 0, 0, 0, 0, 2, 0, 0, 1, 3, 2, 2, 1, 2,
       2, 0, 1, 2, 2, 2, 2, 1, 3, 1, 1, 1, 2, 3, 3, 0, 3, 3, 0, 0, 3, 0,
       0, 0, 3, 3, 1, 2, 0, 0, 1, 1, 2, 0, 0, 0, 3, 2, 2, 1, 3, 1, 2, 3,
       0, 3, 3, 1, 3, 1, 3, 0, 1, 1, 2, 0, 2, 2, 1, 0, 0, 0, 1, 2, 1, 2,
       0, 0, 0, 0, 2, 1, 1, 0, 3, 2, 2, 3, 3, 2, 2, 0, 0, 2, 1, 2, 3, 2,
       3, 1, 3, 2, 0, 1, 1, 3, 3, 2, 1, 3, 3, 2, 0, 1, 3, 2, 0, 3, 0, 2,
       3, 2, 2, 2, 3, 3, 3, 2, 0, 2, 0, 1, 0, 0, 0, 0, 3, 0, 3, 0, 2, 3,
       1, 0, 2, 2, 3, 2, 3, 1, 1, 2, 1, 3, 2, 0, 1, 2, 1, 0, 2, 3, 1, 2,
       0, 0, 1, 3, 1, 0, 2, 2, 3, 1, 3, 1, 2, 1, 2, 3, 3, 2, 3, 1, 1, 3,
       3, 1, 2, 0, 0, 1, 3, 1, 3, 1, 3, 0, 3, 3, 0, 0, 1, 0, 3, 0, 2, 0,
       0, 2, 1, 1, 0, 2, 2, 2, 2, 1, 2, 3, 3, 1, 0, 1, 1, 2, 3, 2, 2, 0,
       3, 3, 1, 2, 2, 0, 1, 2, 1, 1, 3, 3, 1, 2, 1, 3, 2, 2, 3, 1, 2, 2,
       1, 1, 2, 0, 3, 3, 2, 0, 0, 1, 3, 0, 2, 3, 0, 2, 2, 1, 0, 0, 0, 3,
       2, 1, 1, 3, 3, 3, 2, 0, 1, 1, 1, 2, 0, 1, 0, 0, 0, 3, 1, 2, 0, 0,
       0, 3, 0, 2, 3, 3, 3, 0, 3, 3, 1, 3, 2, 2, 3, 1, 0, 2, 1, 1, 3, 0,
       3, 3, 3, 1, 3, 2, 0, 3, 3, 3, 2, 3, 3, 2, 2, 1, 2, 3, 2, 0, 3, 0,
       1, 2, 1, 0, 3, 2, 2, 1, 2, 1, 1, 2, 1, 0, 0, 3, 3, 1, 1, 1, 2, 0,
       1, 3, 0, 0, 3, 3, 2, 1, 1, 0, 0, 3, 0, 1, 3, 1, 1, 3, 2, 3, 0, 3,
       0, 1, 1, 1, 1, 2, 1, 1, 3, 2, 0, 1, 1, 3, 2, 0, 3, 3, 0, 3, 2, 1,
       2, 2, 2, 2, 1, 3, 1, 0, 2, 1, 2, 3, 3, 2, 0, 0, 0, 2, 2, 3, 2, 2,
       3, 3, 3, 1, 2, 1, 1, 3, 3, 1, 2, 1, 3, 2, 2, 2, 3, 3, 3, 0, 1, 1,
       0, 1, 1, 3, 3, 3, 2, 2, 0, 0, 0, 0, 0, 2, 3, 3, 3, 1, 3, 1, 1, 0,
       0, 0, 2, 3, 2, 2, 2, 1, 3, 0, 2, 0, 0, 0, 0, 0, 2, 0, 2, 3, 0, 0,
       2, 1, 3, 3, 0, 0, 1, 3, 3, 3, 0, 3, 3, 2, 2, 2, 0, 0, 0, 1, 3, 0,
       3, 1, 2, 1, 0, 1, 3, 1, 1, 0, 1, 1, 0, 2, 2, 1, 2, 1, 3, 1, 3, 2,
       2, 3, 0, 2, 2, 1, 2, 1, 2, 0, 3, 0, 2, 2, 1, 2, 2, 1, 3, 1, 1, 0,
       1, 2, 1, 1, 2, 1, 3, 3, 2, 1, 1, 0, 3, 2, 0, 0, 3, 3, 2, 1, 2, 3,
       1, 1, 2, 2, 2, 1, 2, 0, 0, 2, 2, 0, 3, 1, 3, 1, 0, 0, 2, 3, 1, 0,
       2, 2, 1, 1, 3, 2, 2, 3, 2, 3, 1, 2, 0, 3, 3, 2, 1, 2, 2, 2, 0, 2,
       1, 3, 3, 2, 3, 1, 1, 3, 2, 3, 3, 2, 0, 1, 3, 0, 0, 2, 1, 2, 2, 1,
       3, 2, 3, 1, 3, 0, 0, 2, 0, 2, 1, 3, 1, 2, 0, 0, 3, 0, 3, 0, 0, 3,
       2, 2, 2, 0, 3, 1, 1, 1, 2, 0, 0, 0, 1, 0, 2, 1, 0, 0, 3, 1, 1, 3,
       2, 0, 2, 2, 2, 0, 2, 2, 0, 2, 0, 1, 0, 1, 1, 2, 1, 3, 0, 2, 2, 2,
```

```
       0, 2, 3, 1, 0, 1, 3, 1, 1, 3, 0, 1, 0, 0, 1, 2, 1, 0, 2, 3, 0, 0,
       0, 0, 2, 3, 2, 3, 1, 0, 3, 3, 2, 0, 3, 3, 2, 1, 0, 3, 3, 1, 1, 0,
       2, 0, 2, 1, 2, 2, 2, 2, 3, 3, 1, 2, 1, 0, 2, 3, 2, 3, 2, 1, 0, 3,
       1, 2, 3, 2, 0, 1, 3, 2, 0, 3, 3, 3, 2, 1, 1, 1, 2, 3, 2, 3, 0, 2,
       2, 3, 0, 3, 0, 3, 1, 1, 1, 2, 0, 1, 2, 1, 3, 3, 1, 0, 1, 0, 0, 1,
       3, 3, 3, 1, 0, 2, 2, 0, 3, 2, 0, 3, 1, 2, 3, 1, 1, 3, 3, 1, 2, 2,
       2, 0, 1, 3, 3, 0, 3, 0, 0, 0])
```

In [47]:

```
#obtenemos el total de registros
categorias_codificadas.shape
```

Out[47]:

```
(1000,)
```

Aquí utilizamos el metodo resape en la lista obtenida de categorías_codificadas y para convertirla en una lista de listas, ya que el codificador de **OneHotEncoder** en su método fit_transform solo admite esto como parámetro.

In [48]:

```
categorias_oh_codificadas = ohcodificador.fit_transform(categorias_codificadas.reshape(1000,1))
categorias_oh_codificadas
```

Out[48]:

```
<1000x4 sparse matrix of type '<class 'numpy.float64'>'
 with 1000 stored elements in Compressed Sparse Row format>
```

Lo que nos devuelve el OneHotEncoder es más conocido como "matriz escasa" (sparse matrix) y es una manera de represesentar matrices con muchos ceros para consumir muy poca memoria. esta variable se puede convertir a una estructura de array de la siguiente forma:

In [49]:

```
categorias_oh_codificadas.toarray()
```

Out[49]:

```
array([[0., 0., 0., 1.],
       [1., 0., 0., 0.],
       [0., 0., 0., 1.],
       ...,
       [1., 0., 0., 0.],
       [1., 0., 0., 0.],
       [1., 0., 0., 0.]])
```

Eficiencia

Ahora realizaremos una comparación en memoria de una matriz escasa y su correspondiente np.array usando la función **sys.getsizeof** que nos devuelve el uso de memoria de un objeto de python en bytes.

In [50]:

```
import sys
#Obtenemos el espacio de memoria en bytes de la matriz sparse
sys.getsizeof(categorias_oh_codificadas)
```

Out[50]:

```
56
```

In [51]:

```
#obtenemos el espacio de memoria en bytes del array de la matriz
sys.getsizeof(categorias_oh_codificadas.toarray())
```

Out[51]:

```
32112
```

Podemos comprobar que es mucho más eficiente una matriz escasa antes que el array. Igualmente si queremos crear un transformador OneHotEncoder y almacenarlo en un np.array podemos hacerlo asignandole al parámetro sparse que sea igual a *False*

In [52]:

```
oh_codificador = preprocessing.OneHotEncoder(sparse=False)
categorias_oh_codificadas = oh_codificador.fit_transform(categorias_codificadas.reshape(1000,1))
categorias_oh_codificadas
```

```
/opt/anaconda3/lib/python3.6/site-packages/sklearn/preprocessing/_encoders.py:371: FutureWarning:
The handling of integer data will change in version 0.22. Currently, the categories are determined
based on the range [0, max(values)], while in the future they will be determined based on the
unique values.
If you want the future behaviour and silence this warning, you can specify "categories='auto'".
In case you used a LabelEncoder before this OneHotEncoder to convert the categories to integers, t
hen you can now use the OneHotEncoder directly.
  warnings.warn(msg, FutureWarning)
```

Out[52]:

```
array([[0., 0., 0., 1.],
       [1., 0., 0., 0.],
       [0., 0., 0., 1.],
       ...,
       [1., 0., 0., 0.],
       [1., 0., 0., 0.],
       [1., 0., 0., 0.]])
```

In [53]:

```
oh_codificador.feature_indices_
```

```
/opt/anaconda3/lib/python3.6/site-packages/sklearn/utils/deprecation.py:77: DeprecationWarning: Fu
nction feature_indices_ is deprecated; The ``feature_indices_`` attribute was deprecated in
version 0.20 and will be removed 0.22.
  warnings.warn(msg, category=DeprecationWarning)
```

Out[53]:

```
array([0, 4])
```

Pandas tiene la funcion auxiliar **get_dummies** que hace esto automáticamente de forma más facil

In [54]:

```
pd.get_dummies(datos.col_categorica).head()
```

Out[54]:

	elefante	gato	perro	ratón
0	0	0	0	1
1	1	0	0	0
2	0	0	0	1
3	0	1	0	0
4	0	1	0	0

Texto

Veremos como vectorizar texto con el paquete feature_extraction de sklearn. Aplicaremos el ejemplo soble la columna col_texto que incluye frases del quijote.

In [55]:

```
from sklearn import feature_extraction
datos.col_texto.values[:5]
```

Out[55]:

```
array(['Tenía en su casa una ama que pasaba de los cuarenta, y una sobrina que no llegaba a los ve
inte, y un mozo de campo y plaza, que así ensillaba el rocín como tomaba la podadera.',
       'El resto della concluían sayo de velarte, calzas de velludo para las fiestas con sus
pantuflos de lo mismo, los días de entre semana se honraba con su vellori de lo más fino.',
       'El resto della concluían sayo de velarte, calzas de velludo para las fiestas con sus
pantuflos de lo mismo, los días de entre semana se honraba con su vellori de lo más fino.',
       'Una olla de algo más vaca que carnero, salpicón las más noches, duelos y quebrantos los sá
bados, lentejas los viernes, algún palomino de añadidura los domingos, consumían las tres partes d
e su hacienda.',
```

```
       'Tenía en su casa una ama que pasaba de los cuarenta, y una sobrina que no llegaba a los ve
inte, y un mozo de campo y plaza, que así ensillaba el rocín como tomaba la podadera.'],
      dtype=object)
```

Para convertir texto en variables numéricas, se puede proceder de igual forma que con las variables categóricas, simplemente separando las palabras antes. Para ello se utilizarán **vectorizadores** de sklearn que convierten el texto en vectores.
CountVectorizer devuelve un vector con el valor 0 en todas las palabras que no existen en una frase y con el número de ocurrencias de las palabras que si existen.

Para que los conceptos queden claros, vamos a realizar un ejemplo que ejemplifique este concepto de forma más sencilla

In [56]:

```
ejemplo_frases=['los coches son rojos',
                'los aviones son rojos',
                'los coches y los aviones son rojos',
                'los camiones son rojos'
                ]
vectorizador_count=feature_extraction.text.CountVectorizer()
x= vectorizador_count.fit_transform(ejemplo_frases)
x
```

Out[56]:

```
<4x6 sparse matrix of type '<class 'numpy.int64'>'
 with 17 stored elements in Compressed Sparse Row format>
```

In [57]:

```
pd.DataFrame(x.toarray(),columns=vectorizador_count.get_feature_names())
```

Out[57]:

	aviones	camiones	coches	los	rojos	son
0	0	0	1	1	1	1
1	1	0	0	1	1	1
2	1	0	1	2	1	1
3	0	1	0	1	1	1

Esto realmente provoca un problema, y es que da mayor peso a aquellas palabras que aparecen muchas veces pero que no aporta valor semántico (por ejemplo, son o los).
Para ello podemos utilizar el vectorizador TfidVectorizer() que realmente se encarga de medir la frecuencia del texto ya que es una medida que asigna valores a cada palabra en función de la frecuencia de aparición en todos los documentos.

In [58]:

```
vectorizador_tfidf = feature_extraction.text.TfidfVectorizer()
```

In [59]:

```
x = vectorizador_tfidf.fit_transform(ejemplo_frases)
pd.DataFrame(x.toarray(),columns=vectorizador_tfidf.get_feature_names())
```

Out[59]:

	aviones	camiones	coches	los	rojos	son
0	0.000000	0.00000	0.657341	0.435087	0.435087	0.435087
1	0.657341	0.00000	0.000000	0.435087	0.435087	0.435087
2	0.464810	0.00000	0.464810	0.615306	0.307653	0.307653
3	0.000000	0.74187	0.000000	0.387139	0.387139	0.387139

Lo que ha hecho ha sido asignar 'pesos' de aparición en el texto. En el ejemplo vemos 'camiones' que la considera de más peso aunque solo aparece una vez.